

Ayudantia para Trabajo Semestral

Predicción de Inflación en Chile

Introducción a la Econometría

Por Ignacio Garrido U.

Objetivo: Construir, interpretar y validar un modelo para predecir inflación mensual (IPC) con foco en teoría, datos y validación fuera de muestra.

¿Qué es Econometría?

- Integración de **Economía + Estadística + Matemáticas + Programación.**
- Responde preguntas empíricas:
 - ¿Cómo se relacionan las variables?
 - ¿Podemos predecir eventos económicos?
- La tecnología (Python, R, Stata) permite:
 - Modelos complejos,
 - Bases de datos masivas,
 - Automatizar validaciones.

Econometría en macro y microeconomía

- **Micro:** hogares, empresas, consumo, deuda.
- **Macro:** inflación, empleo, PIB, tipo de cambio.
- Dos fines:
 - **Explicar** relaciones.
 - **Predecir** futuro.
- Pilar clave: teoría + datos + validación.

Dónde buscar literatura confiable

- Evitar blogs o documentos sin revisión.
- Portales recomendados:
 - **Web of Science (WOS)**
 - **SCOPUS**
 - **SciELO**
 - **IDEAS/RePEc**
- Google Scholar sirve, pero requiere criterio.

Cómo leer un paper correctamente

- No basta con mencionarlo.
- Lectura debe ser **cronológica y conectada**.
- Orden recomendado:
 - ① Problema económico.
 - ② Teoría que lo respalda.
 - ③ Datos: fuente, frecuencia.
 - ④ Modelo aplicado.
 - ⑤ Resultados.
 - ⑥ Limitaciones.

Fuentes de datos recomendadas

- **Banco Central de Chile:** TPM, dólar.
- **INE:** IPC mensual.
- **SII:** series tributarias.
- **CMF:** crédito, bancos.
- Páginas útiles:
 - Datosmacro.com (no oficial).

Frecuencia y consistencia

- El IPC es **mensual**.
- Variables explicativas deben:
 - Estar alineadas a la misma frecuencia.
 - No tener fechas faltantes.
- Unificar unidades y escalas antes de modelar.

Variable dependiente y explicativas

Dependiente

IPC mensual (% m/m).

Explicativas

- TPM rezagada,
 - USD/CLP rezagado,
 - Cobre,
 - Rezagos del IPC,
 - Expectativas económicas.
-
- Clave: misma frecuencia y misma cantidad de datos.

Formato de datos

- CSV (recomendado): liviano y universal.
- XLSX: más pesado, depende de Excel.
- Arrays/listas: eficientes pero menos descriptivos.

Carga y creación de rezagos

```
1 df = pd.read_csv("dataset_inflacion.csv", parse_dates=["fecha"])
2 df = df.sort_values("fecha").reset_index(drop=True)
3
4 for col in ["ipc_mom", "tpm", "usdclp"]:
5     df[f"{col}_lag1"] = df[col].shift(1)
6     df[f"{col}_lag2"] = df[col].shift(2)
7
8 df = df.dropna().reset_index(drop=True)
9 df.head()
```

Estimación OLS (modelo base)

```
1 X = df[["ipc_mom_lag1", "tpm_lag1", "usdclp_lag1"]]  
2 X = sm.add_constant(X)  
3 y = df["ipc_mom"]  
4  
5 ols = sm.OLS(y, X).fit(cov_type="HC1")  
6 print(ols.summary())
```

Interpretación del resumen

- R^2 : proporción explicada.
- R^2 **ajustado**: corrige sobreparametrización.
- **Prueba F**: significancia global.
- **Coeficientes**: dirección y magnitud.
- **p-valores**: evidencia estadística.
- **Errores robustos HC1**: corrigen heterocedasticidad.

Ejemplo de resultados

	Coeficiente	Error Std.	p-valor
Constante	0.152	0.041	0.001
IPC_{t-1}	0.473	0.052	0.000
TPM_{t-1}	0.018	0.007	0.014
USD/CLP_{t-1}	0.00042	0.00019	0.028
R²		0.52	
R² ajustado		0.51	
F-statistic	34.21 (p = 0.000)		
N		108	

Modelo estimado con errores estándar robustos (HC1).

Normalidad y autocorrelación: ¿qué mide cada prueba?

- **Jarque–Bera (JB)**

- Evalúa si los residuos tienen **asimetría** y **curtosis** compatibles con una distribución normal.
- **H0**: los residuos son normales.
- **Interpretación**: p-valor bajo $\Rightarrow$ evidencia contra normalidad.

- **Anderson–Darling (AD)**

- Prueba de normalidad enfocada especialmente en las **colas** de la distribución.
- **H0**: residuos normales.
- Estadístico alto $\Rightarrow$ residuos no normales.

- **Durbin–Watson (DW)**

- Detecta **autocorrelación de primer orden** en los residuos.
- Valores típicos:
 - $2 \Rightarrow$ sin autocorrelación
 - $< 2 \Rightarrow$ autocorrelación positiva
 - $> 2 \Rightarrow$ autocorrelación negativa

Normalidad y autocorrelación: ¿qué mide cada prueba?

```
1 resid = ols.resid
2 print("JB:", jarque_bera(resid))
3 print("AD:", normal_ad(resid))
4 print("DW:", durbin_watson(resid))
```

Heterocedasticidad, VIF y RESET: significado e interpretación

- **Breusch–Pagan (BP)**

- Detecta si la varianza de los residuos es **no constante** (heterocedasticidad).
- **H0**: homocedasticidad.
- p-valor bajo $\Rightarrow$ heterocedasticidad presente.
- Solución frecuente: usar errores robustos (HC0, HC1).

- **VIF (Variance Inflation Factor)**

- Mide **multicolinealidad** entre regresores.
- Valores típicos:
 - $VIF = 1 \Rightarrow$ sin colinealidad.
 - 5–10 $\Rightarrow$ colinealidad moderada.
 - $> 10 \Rightarrow$ colinealidad severa.
- Colinealidad elevada $\Rightarrow$ coeficientes inestables y errores grandes.

- **RESET de Ramsey** (si decides mencionarlo)

- Evalúa **mala especificación funcional**.
- Detecta si faltan términos no lineales o variables omitidas.

Heterocedasticidad, VIF y RESET: significado e interpretación

```
1 Xtr = sm.add_constant(df[["ipc_mom_lag1","tpm_lag1","usdclp_lag1"]])
2 mod = sm.OLS(df["ipc_mom"], Xtr).fit()
3
4 print("BP:", het_breuschpagan(mod.resid, Xtr))
5
6 [(c, variance_inflation_factor(Xtr.values,i))
7   for i,c in enumerate(Xtr.columns)]
```

Predicción del último período

- Entrenar con toda la base menos el último mes.
- Predecir el último mes conocido.
- Si predicción $\approx$ real $\Rightarrow$ modelo estable.
- Si no $\Rightarrow$ revisar variables, rezagos o forma funcional.

Uso responsable de IA

- Útil para:
 - Explicar errores de código,
 - Revisar sintaxis,
 - Entender conceptos.
- No confiable en:
 - Referencias y papers (puede inventarlos),
 - Datos oficiales,
 - Cálculos econométricos avanzados.
- Úsenla como apoyo, no como verdad absoluta.

- Mejoren, comparen, validen.
- Pregunten con tiempo si tienen dudas.
- Este trabajo los inicia en el mundo real de los datos.

y... Bienvenidos al mundo de los datos